

《数据处理与可视化应用课程设计》

技术报告

课题名称：_网站论坛重复问题检测 —
数据处理、可视化与预测建模_____

学 院：___信息工程学院_____

专 业：___数据科学与大数据技术_____

班 级：___本一_____

姓 名：___孙振皓_____

学 号：___4405230211_____

提交日期：_2026_年_7_月_15_日

学术诚信与数据合规声明

本团队郑重声明：

- 本报告所陈述的内容、数据、图表与代码成果均为团队独立完成，无抄袭、剽窃、伪造、篡改等学术不端行为，所有引用内容均已在参考文献中规范标注，无版权纠纷。
- 本课题所使用的所有数据均来源合规合法，严格遵守《中华人民共和国数据安全法》《个人信息保护法》及对应平台的使用协议与版权要求，未采集、使用、传播涉密数据、个人隐私数据与违规数据，数据集可追溯、可验证。
- 本报告与配套成果完全符合课程考核要求，若出现违规行为，团队全体成员自愿承担相应责任与课程考核后果。

签字：

_2026_年7_月__15__日

最终成果交付清单

本课题最终交付全套成果如下，与本报告一同提交归档：

- 本《课程设计技术报告》终稿电子版+纸质版
- 完整可运行的可视化系统/程序源代码、代码注释与运行环境说明
- 课题所用完整数据集、数据字典与数据合规性说明文件
- 5分钟左右成果演示视频
- 其他补充材料

摘要与关键词

中文摘要

本课题以网站论坛重复问题检测为研究内容，基于海豚人工智能与大数据实验室平台的Quora问题对公开数据集（约36万条记录），构建了"数据预处理—可视化分析—预测建模"全流程方案。在数据预处理阶段，完成缺失值清洗和15个工程特征的构造（覆盖基础文本长度、文本相似度、TF-IDF语义相似度及问题结构四个维度），原始字段完整度达100%。在可视化阶段，实现了8种图表类型和基于Plotly的2种交互式功能。在预测建模阶段，分别采用逻辑回归、随机森林和XGBoost三种算法，通过5折交叉验证和网格搜索超参数优化，最佳模型AUC-ROC达0.8021。特征重要性分析表明，Jaccard相似度和单词共享比例是判断问题重复性的最关键因素。基于分析结论，提出了自动去重、搜索优化等五项业务策略建议。

关键词

数据处理；数据可视化；重复问题检测；文本相似度；XGBoost；Python

目录

第1章 绪论

- 1.1 课题研究背景与意义
- 1.2 国内外研究现状
- 1.3 课题研究目标与内容
- 1.4 报告组织结构

第2章 需求分析与总体方案设计

- 2.1 业务需求分析
- 2.2 功能需求分析
- 2.3 非功能需求分析
- 2.4 需求变更说明
- 2.5 总体技术架构设计
- 2.6 技术选型与说明

第3章 数据处理全流程技术实现

- 3.1 数据来源与合规性说明
- 3.2 数据概览与基本信息
- 3.3 数据清洗与预处理
- 3.4 数据分析与特征工程
- 3.5 数据存储方案实现

第4章 可视化系统设计与技术实现

- 4.1 可视化系统总体设计
- 4.2 核心可视化模块详细设计与实现
 - 4.2.1 模块一：目标变量分布模块
 - 4.2.2 模块二：文本长度分析模块
 - 4.2.3 模块三：词云语义分析模块
 - 4.2.4 模块四：特征相关性分析模块
- 4.3 核心交互功能技术实现
- 4.4 视觉设计规范与实现

第5章 成果展示与应用价值分析

- 5.1 核心成果完成度对比
- 5.2 系统核心功能展示
- 5.3 核心数据分析结论
- 5.4 应用价值与落地性分析

第6章 总结与展望

- 6.1 课题工作总结
- 6.2 核心难点与解决方法

6.3 能力提升与课程收获

6.4 不足与未来优化方向

参考文献

第1章 绪论

1.1 课题研究背景与意义

随着Quora、知乎、Stack Overflow等问答社区的快速发展，用户生成内容呈爆炸式增长。Quora平台发布的Quora Question Pairs数据集显示，约37%的问题对为语义重复问题。重复提问导致优质答案被稀释、用户检索效率下降、平台运营成本增加。因此，基于数据驱动的自动重复问题检测技术具有迫切的现实需求。本课题的应用场景为在线问答社区，服务对象包括平台运营管理者、社区用户及内容审核人员。

在理论层面，本课题通过对比多种特征构造方法和分类算法在重复问题检测任务上的表现，丰富了文本相似度计算的实证研究。在实际应用层面，基于Jaccard相似度与TF-IDF余弦相似度的检测机制可实时匹配已有问题，预计减少30%-40%的重复提问量。此外，本课题全面覆盖了数据清洗、特征工程、可视化、机器学习建模四大核心知识模块，是对课程理论的系统性综合应用。

1.2 国内外研究现状

文本相似度计算经历了三个阶段：早期基于字符串匹配的方法（编辑距离、Jaccard相似系数、最长公共子序列）速度快但无法处理语义变换；中期基于向量空间模型的方法（TF-IDF、LSA、LDA）引入了术语权重和隐语义维度，但仍属词袋模型范畴；近年来深度学习方法占据主导，Word2Vec、BERT、Sentence-BERT等预训练模型在语义相似度任务上取得了突破性性能。在应用层面，Quora于2017年发布了Question Pairs竞赛数据集，推动了重复问题检测技术的研究；国内知乎采用了FastText分类模型结合规则引擎实现实时去重，百度知道利用用户点击行为隐式标注重复问题对。

深度学习方法虽性能优异，但模型体积大、部署成本高，对中小型论坛不友好。本课题的研究定位在于：以手工特征+传统机器学习的轻量方案为核心，注重特征工程的系统性与可解释性，兼顾模型对比的全面性，强调分析结论的业务可操作性。

1.3 课题研究目标与内容

本课题的总体目标为：基于网站论坛问题数据集，构建"数据预处理—特征工程—可视化分析—预测建模"全流程方案。

四项核心研究内容：（1）数据预处理与质量保障，完成缺失值、重复值、异常值处理，原始字段完整度达100%；（2）特征工程，构造覆盖四个维度的15个工程特征，完成相关性分析；（3）多维度可视化与交互功能，实现8种图表类型和2种交互式功能；（4）预测建模与优化，采用三种算法、5折交叉验证和网格搜索，基于特征重要性提出策略建议。四项内容全部按计划完成，部分指标超额达成（特征数超出预期25%，图表类型超出预期167%），实施过程中无需求变更。

1.4 报告组织结构

本报告共分六章：第1章绪论阐述研究背景、现状与目标；第2章进行需求分析与方案设计；第3章详述数据处理全流程；第4章详述可视化系统设计；第5章展示成果与分析结论；第6章总结工作与展望未来。

第2章 需求分析与总体方案设计

2.1 业务需求分析

本课题业务场景为在线问答社区的重复问题识别与管理。目标用户包括平台运营管理者、社区用户和内容审核人员。核心业务诉求为：自动检测新提交问题与已有问题库的相似度，当超过阈值时推荐已有回答或提醒合并处理。核心指标体系包括问题对重复率（约37%）、文本相似度指标（Jaccard相似度、TF-IDF余弦相似度等）和模型检测准确率。分析维度涵盖文本长度分布、重复/非重复问题的词汇特征差异、相似度指标的区分能力以及模型性能对比

2.2 功能需求分析

本课题实现的功能模块覆盖数据处理全流程：数据读取与加载（读取CSV文件，输出行数、字段类型、统计描述）；数据清洗（处理缺失值、异常值、重复值，标准化数据类型）；特征工程（构造15个覆盖四维度的工程特征）；可视化分析（生成8种图表类型，涵盖数据分布、长度分析、词汇分析、特征关联、相似度对比五个维度）；交互式功能（悬停详情查阅和图例筛选/切换）；预测建模（训练3个模型，完成5折交叉验证和网格搜索超参数优化，输出特征重要性排名与业务策略建议）。与开题报告相比无功能增减。

2.3 非功能需求分析

性能方面，单次模型推理千条数据耗时 ≤ 1 秒；稳定性方面，全流程连续运行3次无

报错；可复现性方面，固定随机种子后两次运行关键指标偏差≤0.5%；内存效率方面，峰值内存占用≤2GB；数据安全方面，使用公开合法数据集；代码规范方面，关键步骤均有中文注释，模块结构清晰。

2.4 需求变更说明（如有）

无

2.5 总体技术架构设计

本课题采用分层架构，自底向上分为五层：数据层（原始CSV文件，含5个字段）、处理层（基于Pandas和NumPy完成清洗与特征工程，输出含15个特征的DataFrame）、分析层（基于Sklearn和XGBoost完成特征缩放、数据集7:3划分、模型训练、5折交叉验证和网格搜索优化）、可视化层（Matplotlib/Seaborn生成静态图表，Plotly生成交互式图表）、应用层（基于特征重要性分析提炼五项业务策略建议）。各层数据流单向传递：数据层→处理层→分析层→可视化层→应用层。

2.6 技术选型与说明

【填写提示】以表格形式明确全流程最终使用的技术栈，说明选型依据与实际应用效果，与开题报告选型有调整的需标注说明，示例如下：

技术环节	最终选用工具/技术栈	选型依据与应用场景	与开题方案对比调整说明
数据采集	Python 3.8 + Pandas 2.0 + NumPy 1.24	Pandas完成DataFrame清洗与统计；NumPy支撑矩阵运算	无调整
数据处理	Sklearn (TfidfVectorizer, cosine_similarity, StandardScaler)	TF-IDF提取语义特征，余弦相似度计算文本距离，标准化用于模型输入	无调整

可视化实现	Matplotlib 3.7 + Seaborn 0.13 + Plotly 6.8	Matplotlib/Seaborn生成学术规范静态图表，Plotly实现交互功能	无调整
数据存储	Pandas Pickle (.pkl)	中间数据持久化，模块间传递，读写速度快	无调整
版本控制	VS Code + 模块化Python脚本	各模块独立可运行，main.py统一调度	无调整

第3章 数据处理全流程技术实现

3.1 数据来源与合规性说明

本课题使用的数据集来源于海豚人工智能与大数据实验室平台（<https://labs.xcu.edu.cn/user-center/data-center/list>），数据集名称为“网站论坛的问题数据集”，收录于该平台“新闻媒体”类别下。该数据集属于九项英文自然语言理解任务benchmark数据集之一，其中Quora问题对数据集（QQP）包含问答论坛Quora上的约36万对问题及每对问题是否为释义（重复）的标注标签。数据集大小为50MB，包含qid1、qid2、question1、question2、is_duplicate共5个字段，CSV格式存储。该数据集为公开学术benchmark数据集，不包含用户个人身份信息，不涉及数据安全相关法规的受限数据。本课题对数据的使用严格遵守课程平台使用协议，仅用于课程学习与学术研究。

3.2 数据采集技术实现

本课题使用海豚实验室平台提供的现成CSV文件，无需编写爬虫。考虑到完整数据集大小（50MB，36万行），实际分析时采用Pandas的nrows参数分批读取策略，加载前200,000行用于建模分析。加载后数据概览显示：200,000行数据中，question1和question2各缺失6条，is_duplicate缺失8条，qid2缺失4条，总体缺失率<0.01%；正样本（重复问题）占比36.95%，存在类别不平衡现象。

3.3 数据清洗与预处理

缺失值处理：question1和question2是文本分析核心输入，is_duplicate是监督学习标签，缺失时无法合理填充，采用直接删除策略，共删除8条记录。数据类型标准化：qid1和qid2转为int类型，is_duplicate转为int类型，question1和question2转为str类型。重复值检查：完全重复行数为0，忽略顺序的相同问题对重复数也为0。异常值检测：采用 3σ 原则检测文本长度极端值，问题1检测出2,588条异常（1.29%），因其可能包含更多语义信息，予以保留。清洗前后对比：总行数从200,000降至199,992，字段完整度从≈99.99%提升至100%，缺失值占比降至0%。

3.4 数据分析与特征工程

本课题构造了四组共15个工程特征。基础文本长度特征（7个）：计算两个问题的字符长度、单词数量及两者之差与比。文本相似度特征（3个）：共同单词数、Jaccard相似度、单词共享比例，其中Jaccard相似度在重复组均值0.43、非重复组均值0.26

，差异显著。语义相似度特征（1个）：对5万条采样数据使用TF-IDF向量化后计算余弦相似度，未采样部分用中位数填充。问题结构特征（4个）：标记是否包含问号和是否以疑问词开头（99.9%的问题含问号，约90%以疑问词开头）。相关性分析表明，与目标变量正相关最强的三个特征为Jaccard相似度（相关系数约0.35）、单词共享比例（约0.33）、TF-IDF余弦相似度（约0.29），构成后续建模的核心特征集。

3.5 数据存储方案实现

采用Pandas Pickle格式（.pkl）作为中间数据存储方案。清洗及特征工程处理后的DataFrame（199,992行×20列）序列化保存至output/cleaned_data.pkl（约44MB）。选择该方案的原因是读写速度快（约2-3秒）、完整保留DataFrame数据类型和结构、与Pandas生态无缝集成。数据调用逻辑为：预处理模块负责写入，可视化和数据挖掘模块通过pd.read_pickle()直接读取，各模块间通过共享该文件实现数据传递，无需重复执行预处理流程。

4.1 可视化系统总体设计

本可视化系统采用“总览概览→特征分析→关联挖掘→深度对比”的层级叙事逻辑，引导用户从宏观到微观逐层深入。系统设计核心原则包括：以业务为核心（所有图表围绕“什么因素决定两个问题是否重复”展开）、直观性（优先使用柱状图、饼图等通用类型）、交互性（关键对比场景提供悬停和图例筛选）、配色一致性（非重复问题统一用蓝色#2a78d6，重复问题统一用红色#e34948）。

系统分为四个可视化模块：模块一“目标变量分布”作为总览入口；模块二“文本特征分析”从字符长度和词云两个维度刻画语言特征；模块三“特征关联分析”通过热力图揭示特征间相关性；模块四“相似度对比分析”利用交互式散点图和雷达图支持深度探索。四个模块从宏观到微观递进。

4.2 核心模块详细设计与实现

模块一：目标变量分布模块。定位为数据总览入口，采用“柱状图+饼图”并排布局：柱状图对比绝对数量，饼图展示相对比例，柱状图上直接标注数值和百分比。分析表明，非重复问题约占63%，重复问题约占37%。

模块二：文本特征分析模块。采用三子图布局（字符长度直方图、单词数量直方图、分组箱线图），另配词云图。问题1和问题2的长度分布高度相似（中位数约51-52字符）；词云显示重复问题对中“people”“difference”“money”“good”等通用话题词更突出。

模块三：特征关联分析模块。采用热力图可视化15个特征与目标变量的相关系数矩阵，使用蓝-白-红发散色板。Jaccard相似度（0.35）、单词共享比例（0.33）、TF-IDF余弦相似度（0.29）正相关最强，字符长度差等基础特征相关较弱。

模块四：相似度对比分析模块。包含交互式散点图和雷达图。散点图以Jaccard相似度为X轴、TF-IDF余弦相似度为Y轴，颜色区分分类，气泡大小表示共同单词数，重复问题对明显聚集于右上高相似度区域。雷达图标准化后对比显示，重复组在所有相似度特征上均显著高于非重复组。

4.3 核心交互功能技术实现

悬停详情查阅：在散点图中，用户悬停任意数据点时自动弹出浮动信息框，显示

该问题对的单词数、相似度指标等详细信息。基于Plotly的hover_data参数实现，解决了静态图"看得到点、看不到值"的痛点。

图例筛选与切换：在散点图和雷达图中，用户点击图例标签可控制对应类别数据点的显示与隐藏。基于Plotly内置的legend点击事件机制，解决了多分类叠加视图的视觉干扰问题。

两种交互功能从微观（精确数据查阅）和中观（分类对比切换）两个层面提升了系统的分析深度，使可视化从静态展示升级为可探索的分析工具。

4.4 视觉设计规范与实现

配色方案：以色盲友好为原则，非重复问题统一用蓝色(#2a78d6)，重复问题用红色(#e34948)，两色在色相上相距约180度；词云中重复组用Reds色带、非重复组用Blues色带，与主配色一致。**字体规范：**标题15pt加粗，子标题13pt加粗，轴标签11pt，图例9-10pt。图表底色为#fcfcfb浅暖白，网格线#e1e0d9，标注#0b0b0b近黑，辅助元素低对比度不干扰数据主体。整体风格简洁克制，符合学术报告定位。

第5章 成果展示与应用价值分析

5.1 核心成果完成度对比

【填写提示】对比开题报告的预期目标与考核指标，以表格形式量化展示最终成果的完成度，示例如下：

序号	预期目标	最终完成情况	完成度	备注
1	数据加载与清洗，≥10万条，完整度≥95%	19.99万条有效数据，完整度100%	100%	超额完成
2	构造特征≥15个	构造15个特征，覆盖4个维度	100%	按计划完成
3	≥3种图表，≥2种交互功能	3个模型，5折CV，72组合网格搜索，AUC=0.8021	100%	按计划完成
4	训练≥3个模型，交叉验证+超参数优化	完成全套成果交付，文档与代码规范完整	100%	按计划完成

5.2 系统核心功能展示

系统共生成8张可视化成果：目标变量分布图（柱状图+饼图）、文本长度分布图（直方图+箱线图）、词云图（重复vs非重复高频词对比）、特征相关性热力图、交互式散点图（悬停详情+图例筛选）、交互式雷达图（分类切换对比）、特征重要性分析图（随机森林+XGBoost双模型对比）、ROC曲线对比图（三模型对比）。图片均保存于output目录，PNG分辨率150dpi，HTML文件可在浏览器中直接打开交互操作。

5.3 核心数据分析结论

（1）数据集中约37%的问题对为语义重复问题，说明重复提问现象普遍，亟需自动检测机制。

（2）Jaccard相似度和单词共享比例是判断重复的最有效指标，重复组均值分别比非重复组高出64%和57%，两个特征在模型中的重要性合计超过50%。

（3）重复问题倾向于更简洁的表达，字符长度均值（约53）比非重复对（约63-64）短约10个字符。

（4）基于手工特征的XGBoost模型AUC-ROC达0.8021，体积小、推理快，适合作为中小型论坛的轻量级去重方案。

（5）文本表层特征（Jaccard、共享比例）对分类的贡献高于深层语义特征（TF-IDF余弦相似度），为实际系统特征设计的优先级提供了量化依据。

5.4 应用价值与落地性分析

实际应用价值：基于相似度特征的自动去重机制可实时匹配已有问题，预计减少30%-40%的重复提问处理工作量；交互式仪表盘为运营人员提供直观洞察；特征重要性排名为搜索算法优化提供依据。可复用性：模块化架构支持数据源替换，切换为中文数据仅需调整分词方式。与深度学习方案相比，本方案模型体积小、推理速度快（千条<1秒）、特征可解释性强、部署成本极低，特别适合资源有限的中小型平台，具有更高的工程性价比。

第6章 总结与展望

6.1 课题工作总结

本课题完成了网站论坛重复问题检测的全流程技术实现：数据预处理阶段完成20万条数据的清洗和15个工程特征的构造；可视化阶段实现8种图表类型和2种交互式功能；预测建模阶段训练并优化了3个模型，最佳AUC-ROC达0.8021。全流程代码采用模块化架构，可复现、可扩展。

6.2 核心难点与解决方法

难点一：TF-IDF在36万条数据上的向量化和余弦相似度计算耗时长。解决方法是5万条随机采样拟合TF-IDF，未采样部分用中位数填充，在不显著损失区分度的前提下降低计算开销。难点二：数据集类别不平衡（重复仅占37%）。解决方法是以AUC-ROC和F1分数为主要评估指标，并采用分层采样保证训练集和测试集类别比例一致。

6.3 能力提升与课程收获

通过本次课程设计，熟练掌握了Pandas数据处理全流程，系统实践了Matplotlib/Seaborn/Plotly多工具链可视化开发，深入理解了特征工程在机器学习项目中的核心地位，完整经历了从原始数据到可部署模型的端到端项目流程。

6.4 不足与未来优化方向

本课题的不足包括：未接入深度学习语义特征，模型性能有提升空间；可视化系统为离线文件，未集成为实时Web仪表盘；未对中文数据进行验证。未来优化方向：引入Sentence-BERT增强语义理解；使用Streamlit构建Web应用；在中文问答数据集上验证方案的可迁移性。

参考文献

- [1] Wes McKinney. 利用Python进行数据分析（第2版）[M]. 徐敬一, 译. 北京: 机械工业出版社, 2018.
- [2] 李航. 统计学习方法（第2版）[M]. 北京: 清华大学出版社, 2019.
- [3] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.
- [4] 刘知远, 孙茂松, 林衍凯, 等. 自然语言处理导论[M]. 北京: 电子工业出版社, 2023.
- [5] 宗成庆. 统计自然语言处理（第2版）[M]. 北京: 清华大学出版社, 2013.
- [6] 车万翔, 郭江, 崔一鸣. 自然语言处理: 基于预训练模型的方法[M]. 北京: 电子工业出版社, 2021.
- [7] Pandas开发团队. Pandas: Python数据分析库官方文档[EB/OL].
<https://pandas.pydata.org/docs/>.
- [8] Scikit-learn开发团队. Scikit-learn: Python机器学习库用户指南[EB/OL].
https://scikit-learn.org/stable/user_guide.html.
- [9] Matplotlib开发团队. Matplotlib: Python可视化库官方文档[EB/OL].
<https://matplotlib.org/stable/contents.html>.
- [10] XGBoost开发团队. XGBoost: 可扩展梯度提升树官方文档[EB/OL].
<https://xgboost.readthedocs.io/>.
- [11] Plotly Technologies. Plotly Python Graphing Library文档[EB/OL].
<https://plotly.com/python/>.
- [12] 海豚人工智能与大数据实验室. 网站论坛的问题数据集[EB/OL].
<https://labs.xcu.dilabs.cn/user-center/data-center/list>.
- [13] 涂铭, 刘祥, 刘树春. Python自然语言处理实战: 核心技术与算法[M]. 北京: 机械工业出版社, 2018.
- [14] 全国信息与文献标准化技术委员会. GB/T 7714-2015 信息与文献 参考文献著录规则[S]. 北京: 中国标准出版社, 2015.